

Выводы по лабораторной № 2

Анализ отзывов о приложении «ПланДень». 19.09.2026.

РЕАЛЬНЫЙ API-ПРОГОН

1. Что получилось

Обработаны 30 синтетических отзывов о вымышленном приложении. Корпус подготовлен с помощью ИИ и используется для проверки метода. Реализованы IE, анализ шести фиксированных аспектов, параллельный Map-Reduce и LLM-as-judge; дополнительно выполнен autodiscovery. Генератор и судья используют DeepSeek (deepseek-flash) в отдельных запросах.

Получены **30 валидных объектов Review из 30**, окончательно потерянных отзывов нет. В основном конвейере три попытки MAP отклонены с Pydantic ValidationError из-за превышения числа фактов; ещё четыре ответа REDUCE оборвались на лимите 5000 токенов. Итого семь неуспешных попыток, а не семь потерянных отзывов. В отдельной диагностике судьи была ещё одна ошибка ValidationError, исправленная повторным запросом. Для завершения введён компактный профиль REDUCE с лимитом 12000 токенов; 17 ранее принятых этапов использованы из кэша.

Проверены **355 вхождений цитат** во всех попытках основного конвейера: ghost-цитат **0 (0%)**. Повторения цитат учитываются отдельно. В итоговой сводке отсутствующих цитат также нет. Дословное совпадение не гарантирует сохранения смысла и оговорок автора.

Оценки judge: faithfulness **0,82**, coverage **0,78**, actionability **0,85**. Итог: $0,4 \times 0,82 + 0,35 \times 0,78 + 0,25 \times 0,85 = \mathbf{0,8135}$, выше порога 0,7. Поэтому повторная сводка по низкой оценке не потребовалась. Судья отметил неполное покрытие тем входа, совместного редактирования и удаления задач.

Учтённое активное время всех запусков составляет **161,52 с**. От создания прогона до завершения прошло **25 мин 54 с**, включая остановку и подготовку продолжения. По 29 ответам, включая неуспешные попытки и диагностику: **130 553 входных, 53 482 выходных** токена, из входных **80 768** обслужены кэшем провайдера. По тарифам, зафиксированным в run.json, расходы составляют **\$0,03980-\$0,07960** для off-peak/peak. Это расчёт через response.usage без налогов, а не сумма из банковской выписки. Все 29 ответов содержат usage.

2. Где модель ошибалась

В поле distortions судья вернул пустой список. Последующая сверка исходников с результатами выявила два случая потери контекста. Они относятся к полученным ответам основного конвейера.

R24, итоговая сводка. Исходник: «Возможно, задел баннер пальцем»; «После возвращения отметка о выполнении не сохранилась. Повторил отметку ещё раз, теперь она на месте». В summary.json: «при открытии рекламы приложение может отправить в магазин другого приложения, после чего отметка о выполнении не сохраняется». Потеряна оговорка о случайном нажатии, а единичное событие передано формой «не сохраняется», создающей впечатление повторяемости. Точнее: один пользователь сообщил о несохранённой отметке после возможного случайного перехода; повторная отметка сохранилась.

R29, этап IE. Исходник: «После обновления напоминания стали приходить стабильно, но перед этим я ещё отключил ограничение фоновой работы. Не могу отделить эффект обновления от настройки телефона». В reviews.json, praise: «После обновления напоминания стали приходить стабильно». Извлечённый фрагмент и его цитата обрываются перед «но» и теряют второе изменение и неопределённость причины. Это неполнота извлечения, а не выдуманная цитата. В итоговой сводке оговорка восстановлена; переносить эту претензию на финальный REDUCE было бы неверно.

Действие судьи. Рекомендация A3 проверить расположение рекламы, чтобы она не мешала отмечать задачи и не приводила к потере отметки, получила weakly_supported. По объяснению judge, R08 подтверждает навязчивость рекламы, но не потерю отметки; R24 описывает один случай с оговоркой. Рекомендацию разумно формулировать как проверяемую гипотезу о случайных нажатиях, без установленной причинной связи. В отдельной контролируемой диагностике судья также отклонил A99 о продаже авиабилетов. Искусственно внесённые диагностические ошибки не включены в два примера выше.

Autodiscovery. Обнаружено шесть тем. Конфликты совместного редактирования и прозрачность офлайн-синхронизации уточняют «надёжность»; доступность интерфейса уточняет «дизайн»; ясность оплаты и продления уточняет «цену». Два кандидата вне фиксированного Literal: **data_export_portability** - экспорт и переносимость задач (R03, R23); **permission_transparency** - понятность запросов разрешений и персональных данных (R09, R17). В отличие от сохранности данных и стоимости подписки, эти темы описывают возможность забрать свои данные и понять необходимость их предоставления. Границы категорий требуют проверки на реальном корпусе.

3. Что бы изменили в production

Сохранила бы Pydantic-схемы, проверки цитат по ID, журнал usage, кэш принятых ответов и отдельную оценку судьи. Для отсутствующих аспектов оставила бы null: он отличается от нейтральной оценки 0 на heatmap.

В IE добавила бы обязательное сохранение оговорок и альтернативных причин, в REDUCE - различие единичного события и повторяемого дефекта. Компактные схемы и ограниченное число цитат уменьшают риск переполнения ответа. Повторы нужны для исправимых ошибок формата; увеличение их числа без устранения причины только повышает расходы. Для длинных отзывов потребовалось бы разбиение с сохранением границ источника.

Добавила бы ручную разметку части реальных отзывов, оценку точности извлечения и A/B на двух моделях, включая независимого судью. Отдельно проверяла бы инструкции внутри отзывов и персональные данные. Одна модель в ролях генератора и судьи может повторять собственные ошибки; синтетический корпус не позволяет делать выводы о реальной клиентской базе.